

家庭电力消耗多步预测实验报告

学生姓名

学院/系所

学号

2026 年 7 月 3 日

作者贡献声明: [作者 1 姓名] 负责数据处理与 LSTM、Transformer 实验; [作者 2 姓名] 负责自改进模型设计与消融实验。

代码仓库: <https://github.com/OnlyHero5/hcmrf-household-forecast>

AI 工具使用声明: 正文结构与部分表述经 ChatGPT 辅助整理, 实验设计、代码实现、数值结果与结论均由作者核对确认。

1 问题介绍

本实验使用 UCI 家庭电力消耗数据集: 法国一户家庭 2006 年 12 月至 2010 年 11 月的分钟级记录, 含全局有功/无功功率、电压、电流及三路分表读数。任务是用过去 90 天的多变量日序列, 分别预测未来 90 天 (短期) 和 365 天 (长期) 的全局有功功率。课程要求实现 LSTM、Transformer 和自改进模型三类方法, 各占三分之一分值; 开放题部分以方法新颖性为主、性能为辅。

数据预处理先将分钟级记录聚合为日级: 有功/无功功率与三路分表按日求和, 电压与电流强度按日平均; 天气变量 (降水、降水天数、雾天等) 按月取值映射到对应日期。在此基础上构造 24 维特征: 日序/月份/星期的正弦余弦编码 (避免 12 月 31 日与 1 月 1 日边界跳变)、7 日与 30 日滞后、7 日与 30 日滑动均值, 以及是否周末。归一化采用最小-最大缩放, 仅在训练集上拟合参数, 评估时将预测反变换回千瓦量纲后再算指标。每个样本的输入为 90×24 , 目标为未来 h 天的有功功率; 滑动步长取 7, 减轻相邻窗口重叠带来的过拟合。

评价指标为均方误差 (MSE) 和平均绝对误差 (MAE)。每种配置重复 5 次实验 (随机种子 42、123、456、789、2024), 报告均值 $\pm$ 标准差。另设季节性朴素基线: 直接取去年同日的用电量作为预测。

2 模型

2.1 LSTM 模型

采用双层 LSTM。输入形状为 $(B, 90, 24)$ ，经两层 LSTM（隐层 128 维，丢弃率 0.2）后取末时刻隐状态，再经全连接层 $128 \rightarrow 64 \rightarrow h$ 输出 h 步预测。优化器为 Adam，学习率 10^{-3} ，批大小 32，最多训练 100 轮，验证集 10 轮无改善则早停。

2.2 Transformer 模型

采用仅含编码器的结构。先将 24 维特征线性映射到 128 维，叠加固定正弦位置编码，再堆叠 2 层编码器（4 头注意力，前馈隐层 256 维，丢弃率 0.1）。对时间维做全局平均池化后，经 $128 \rightarrow 64 \rightarrow h$ 输出得到预测。其余训练设置与 LSTM 相同。

2.3 自改进模型：预测步长特化的多分辨率模型

以下简称为**多分辨率模型**。其核心想法是：90 天和 365 天预测对时间粒度的需求不同——短期要保留日级波动，长期更应关注季节趋势、抑制日噪声。因此为两种步长分别设计编码与解码路径，而不是共用同一套结构。

由于课程要求 90 天与 365 天模型分开训练，每个实例只对应一种预测长度，分支选择是写进网络结构的，并非由模型在线学习。这一点在讨论部分会再说明。

模型包含三个模块：

(1) 多尺度池化。365 天路径将 90 步序列自适应平均池化到约 30 步；90 天路径保持原始分辨率。

(2) 自适应分块 Transformer。365 天路径分块大小为 3（约 30 块），90 天路径分块大小为 1（90 块）。分块后通过线性层映射回 64 维，再经 2 层 Transformer 编码。

(3) 动态分辨率解码器。90 天路径由全连接层直接输出 90 个点。365 天路径先预测 52 周（约 364 天）的粗序列，线性插值到 365 天，再用三层一维卷积（核大小 7，感受野 19）做局部修正。

整体流程：输入 $\mathbf{X}$ 经一维卷积编码得 $\mathbf{H}$ ，多尺度池化得 $\mathbf{H}'$ ，分块 Transformer 得 $\mathbf{Z}$ ，全局池化得 $\mathbf{z}$ ，解码器输出 $\mathbf{Y}$ 。伪代码见算法 1。

Algorithm 1 多分辨率模型前向传播

输入: 输入 $\mathbf{X} \in \mathbb{R}^{B \times 90 \times 24}$, 预测步长 h

输出: 预测 $\mathbf{Y} \in \mathbb{R}^{B \times h}$

```
1:  $\mathbf{H} \leftarrow \text{Conv1D}(\mathbf{X}^T)$  共享卷积编码
2: if  $h = 365$  then
3:    $\mathbf{H} \leftarrow \text{AdaptiveAvgPool}(\mathbf{H}, 30)$  压缩时间分辨率
4: end if
5:  $p \leftarrow 1$  (若  $h = 90$ ) 或 3 (若  $h = 365$ ) 分块大小
6:  $\mathbf{Z} \leftarrow \text{Patch}(\mathbf{H}, p) \rightarrow \text{Linear} \rightarrow \text{Transformer}$ 
7:  $\mathbf{z} \leftarrow \text{GlobalAvgPool}(\mathbf{Z})$ 
8: if  $h = 90$  then
9:    $\mathbf{Y} \leftarrow \text{Linear}_{90}(\mathbf{z})$ 
10: else
11:    $\mathbf{Y}_{\text{coarse}} \leftarrow \text{Linear}_{52}(\mathbf{z})$  周级粗预测
12:    $\mathbf{Y}_{\text{interp}} \leftarrow \text{Interpolate}(\mathbf{Y}_{\text{coarse}}, 365)$ 
13:    $\mathbf{Y} \leftarrow \text{Conv1D\_Refine}(\mathbf{Y}_{\text{interp}})$  卷积精修
14: end if
15: return  $\mathbf{Y}$ 
```

主要超参数: 卷积核 7, 模型宽度 64, Transformer 4 头 2 层, 粗预测 52 周。具体取值依据见第 3.3 节。

3 结果与分析

训练集为 2006-12-16 至 2009-12-31 (1112 天), 测试集为 2010-01-01 至 2010-11-26 (330 天)。90 天任务在测试集内滑动取窗评估; 365 天任务因测试段长度不足, 输入取训练集末尾 90 天, 目标取测试集起始段真实值。指标均在千瓦量纲下计算。

3.1 主实验结果

表 1: 短期预测 (90 天) 结果

模型	MSE (kW ²)	MAE (kW)
季节性朴素基线	566,327	610.0
LSTM	268,942 $\pm$ 9,986	402.3 $\pm$ 5.5
Transformer	251,819 $\pm$ 15,879	397.2 $\pm$ 15.4
多分辨率模型	259,395 $\pm$ 27,947	401.8 $\pm$ 19.9

表 2: 长期预测 (365 天) 结果

模型	MSE (kW ²)	MAE (kW)
季节性朴素基线	343,067	444.5
LSTM	591,410 $\pm$ 17,930	600.7 $\pm$ 9.2
Transformer	487,139 $\pm$ 20,849	542.6 $\pm$ 13.2
多分辨率模型	372,467 $\pm$ 21,793	474.9 $\pm$ 23.2

90 天任务上, 三种神经网络模型的 MSE 约为朴素基线的一半, 彼此差距落在标准差范围内, Transformer 略低 (251,819), 多分辨率模型居中 (259,395)。短期窗口较短, 特征工程和训练策略的影响往往大于结构差异。

365 天任务的情况不同: 朴素基线在 MSE 和 MAE 上均优于全部深度学习模型——去年同日这一简单规则, 已经抓住了年度季节性的主体。在神经网络内部比较, 多分辨率模型 MSE 372,467, 比 Transformer (487,139) 低约 23%, 比 LSTM (591,410) 低约 37%。训练样本只有约 1100 天, 复杂模型容易拟合训练期噪声, 反而在年度外推上吃亏; 这与 M 竞赛等工作中「简单季节模型在长程预测中仍很强」的经验一致。

3.2 消融实验 (365 天)

90 天路径不做池化且分块大小为 1, 消融对其几乎无影响, 因此只在 365 天上报告。

表 3: 消融实验——365 天 MSE

变体	MSE (kW ²)	考察问题
完整模型	372,467 $\pm$ 21,793	—
去掉多尺度池化	377,092 $\pm$ 29,260	压缩分辨率是否有用
去掉自适应分块	395,180 $\pm$ 30,311	动态分块是否优于固定分块
去掉动态解码器	547,034 $\pm$ 12,217	粗到精解码是否必要
去掉共享编码器	382,614 $\pm$ 40,414	两套编码器是否更好

去掉动态解码器后 MSE 升至 547,034 (+47%), 是贡献最大的组件: 直接回归 365 个点误差累积明显, 先预测 52 周再插值、卷积修正更稳。多尺度池化 (+1.2%)、自适应分块 (+6%)、共享编码器 (+3%) 也有正向作用, 但幅度较小。

3.3 超参数消融（365 天）

表 4: 超参数消融——365 天 MSE

超参数	候选值	MSE (kW ²)
池化压缩因子	2	378,139 ± 34,028
	3	372,472 ± 21,795
	4	372,472 ± 21,795
解码器卷积核	3	387,296 ± 87,371
	5	406,937 ± 75,511
	7	372,469 ± 21,794
粗预测周数	26	433,781 ± 37,703
	52	372,473 ± 21,795

压缩因子 3 与 4 结果接近，因子 2 略差；解码器卷积核取 7 时 MSE 最低且方差明显小于 3 和 5；粗预测 52 周优于 26 周。当前配置（因子 3、核 7、52 周）与上述结果一致。

3.4 可视化




图 1: 短期预测（90 天）曲线对比




图 2: 长期预测 (365 天) 曲线对比 (365 天输出较平滑, 难以拟合日级尖峰)




图 3: 消融实验 MSE 对比 (365 天)




图 4: 超参数消融对比 (365 天)

4 讨论

短期任务上，神经网络相对朴素基线的提升是实实在在的，三种结构差别不大。长期任务上，朴素基线仍然最强，说明在这份单户、小样本数据里，年度周期比网络结构更决定误差下限。多分辨率模型的价值主要体现在深度学习内部：365 天上比 Transformer 少约 23% 的 MSE，消融也表明动态解码器不可或缺——去掉它误差立刻回到与 LSTM 相近的水平。

另一方面，多尺度池化和自适应分块的边际收益只有 1%–6%，365 天实验的标准差也偏大 ($\pm 22k$)，说明在 1112 天训练数据下，复杂模块未必划算。若继续改进，更自然的方向是训练单一多任务模型，用步长嵌入或条件调制层让网络自己切换分辨率，而不是为 90 天和 365 天各训一套；天气特征目前只有月粒度、且仅来自一户家庭，泛化性也有限。这些限制已在实现中接受，留作后续工作。

4.1 局限性与后续方向

- **分模型训练**：90 天与 365 天各自独立训练，步长分支无法在线切换；理想做法是共享编码器、双解码头，并用条件调制注入步长信息。
- **数据量**：单户 1112 天，对深层结构偏少。
- **天气特征**：月粒度，同月各日相同，信息有限。
- **泛化性**：结论仅针对这一户法国家庭，外推需谨慎。

参考文献

- [1] Hebrail, O. (2012). Individual household electric power consumption. UCI Machine Learning Repository.
- [2] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [3] Vaswani, A., et al. (2017). Attention is all you need. *NeurIPS*, 30.
- [4] Nie, Y., et al. (2023). A time series is worth 64 words. *ICLR*.
- [5] Makridakis, S., et al. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74.