

家庭电力消耗多步预测实验报告

学生姓名

学院/系所

学号

2026 年 6 月 28 日

作者贡献声明：[作者 1 姓名] 负责数据处理与 LSTM/Transformer 实验；[作者 2 姓名] 负责 HSMRF 模型设计与消融实验。

AI 工具使用声明：本报告撰写过程中使用了 AI 辅助工具进行语言润色，所有实验设计、模型实现、数据分析与结论均由作者独立完成。

1 问题介绍

家庭电力消耗预测是智能电网调度和家庭能源管理的核心技术。本研究使用 UCI “Individual Household Electric Power Consumption” 数据集，该数据记录了法国一户家庭 2006 年 12 月至 2010 年 11 月的分钟级电力消耗，包含有功功率、无功功率、电压、电流强度及三个分表读数等多个变量。预测任务为：基于过去 90 天的多变量观测数据，预测未来有功功率（Global_active_power）的两个时间尺度——短期预测（未来 90 天）和长期预测（未来 365 天）。课程要求完成三个任务：LSTM 模型预测、Transformer 模型预测、自改进模型预测，各占总分三分之一，其中自改进模型以原理新颖程度为首要评价标准。

数据预处理方面，原始分钟级数据按以下规则聚合为日级：Global_active_power、Global_reactive_power、Sub_metering_1、Sub_metering_2、Sub_metering_3 按天求和以反映日总消耗；Voltage 和 Global_intensity 按天平均以反映日均水平；天气变量（RR、NBJRR1/5/10、NJBROU）取当月值映射到每日。特征工程共生成 24 个特征，包括时间周期性特征（sin/cos 编码的 day-of-year、month、weekday，避免边界跳变）、滞后特征（lag_7、lag_30）、滚动统计特征（7 天和 30 天移动平均）以及布尔特征 is_weekend。归一化采用 MinMaxScaler，仅在训练集上 fit 以避免数据泄漏，预测后通过 inverse_transform 还原到原始 kW 量纲计算指标。滑动窗口的每个样本由输入窗口（90 天 × 24 特征）和目标序列（ h 天的 Global_active_power）构成，步长 step=7 以减少相邻样本重叠导致的过拟合风险。

评估指标采用 MSE（均方误差）和 MAE（平均绝对误差），单位均为原始 kW 量纲。实验配置为 5 轮独立实验（随机种子 42、123、456、789、2024），报告均值 ± 标准

差。基线采用季节性朴素预测 (seasonal naive)，即以去年同日的电力消耗值作为预测。

2 模型

2.1 LSTM 模型

采用双层 LSTM 架构，通过门控机制捕捉长期依赖。网络结构为：输入层接收 $(B, 90, 24)$ 维数据，经过两个 LSTM 层 ($\text{hidden_dim}=128, \text{dropout}=0.2$)，取最后时间步的隐藏状态，再经过全连接层 $128 \rightarrow 64 \rightarrow \text{horizon}$ 输出预测。超参数设置为：学习率 10^{-3} ， $\text{batch_size}=32$ ，最大 100 轮（早停 $\text{patience}=10$ ），优化器 Adam。

2.2 Transformer 模型

采用编码器架构加全局平均池化，通过自注意力机制捕捉时序依赖。网络结构为：线性嵌入层将输入从 24 维映射到 $d_{\text{model}} = 128$ 维，加上固定 $\sin/\cos$ 位置编码，经过 2 层 Transformer 编码器 (4 头注意力，FFN 隐藏层 256 维)，然后对时间维度做全局平均池化得到 $(B, 128)$ 维特征，最后通过输出头 $128 \rightarrow 64 \rightarrow \text{horizon}$ 。超参数： $d_{\text{model}} = 128$ ， $n_{\text{heads}}=4$ ， $n_{\text{layers}}=2$ ， $\text{dropout}=0.1$ ，学习率 10^{-3} 。

2.3 自改进模型：Horizon-Specialized Multi-Resolution Forecasting (HSMRF)

2.3.1 设计动机

传统时序预测模型 (LSTM、Transformer) 对不同预测长度使用完全相同的架构——相同的时序分辨率、相同的信息处理路径。我们观察到两个基本事实：

- **短期预测 (90d)** 需要细粒度信息捕捉周模式、设备开关等局部波动
- **长期预测 (365d)** 需要粗粒度结构捕捉季节趋势，同时对日级噪声不敏感

基于此，我们提出 **Horizon-Specialized Multi-Resolution Forecasting (HSMRF)**：根据预测距离设计专门化的多分辨率架构。需要说明的是，由于课程要求 90d 和 365d 模型分别训练，每个模型实例只看到一个 horizon，因此分辨率分支是**架构设计决策** (architectural design choice) 而非可学习的 horizon conditioning。在”讨论”部分我们将分析这一约束，并提出未来改进方向。

2.3.2 架构设计

HSMRF 由三个专门化组件构成：

1. 多尺度池化 (Multi-Scale Pooling)：根据 horizon 调整时序分辨率。90d 路径保持原始 90 步分辨率以捕捉细粒度模式；365d 路径通过 AdaptiveAvgPool1d 压缩到约 30 步，聚焦季节趋势并抑制日级噪声。

2. Adaptive-Patch Transformer: 根据 horizon 动态调整 patch 尺寸实现多粒度注意力。90d 用 patch_size=1 (90 个 patch, 细粒度自注意力); 365d 用 patch_size=3 (30 个 patch, 粗粒度自注意力)。patch 后特征维度变为 $C \times \text{patch_size}$, 通过 Linear 投影恢复到 d_{model} 。

3. 动态分辨率解码器 (DRD): 对 365d 预测采用粗到精解码以缓解误差累积。90d 路径直接多步输出 Dense(90); 365d 路径先做周级粗预测 Dense(52) (52 周 $\approx$ 364 天), 然后线性插值上采样到 365 天, 最后用多层 Conv1D (kernel=7, 感受野 =19) 精修以修正插值平滑伪影。

整体流程为: 输入 $\mathbf{X}$ 经过 Conv1D 编码器得到 $\mathbf{H}$, 经过多尺度池化得到 $\mathbf{H}'$, 经过 Patch 和 Transformer 得到 $\mathbf{Z}$, 全局平均池化得到 $\mathbf{z}$, 最后经过 DRD 输出预测 $\mathbf{Y}$ 。前向传播伪代码如算法1所示。

Algorithm 1 HSMRF 前向传播

Require: 输入 $\mathbf{X} \in \mathbb{R}^{B \times 90 \times 24}$, horizon h
Ensure: 预测 $\mathbf{Y} \in \mathbb{R}^{B \times h}$

- 1: $\mathbf{H} \leftarrow \text{Conv1D}(\mathbf{X}^T)$ {共享编码器}
- 2: **if** $h == 365$ **then**
- 3: $\mathbf{H} \leftarrow \text{AdaptiveAvgPool}(\mathbf{H}, 30)$ {多尺度池化}
- 4: **end if**
- 5: $p \leftarrow (h == 90) ? 1 : 3$ {patch 尺寸}
- 6: $\mathbf{Z} \leftarrow \text{Patch}(\mathbf{H}, p) \rightarrow \text{Linear} \rightarrow \text{Transformer}$
- 7: $\mathbf{z} \leftarrow \text{GlobalAvgPool}(\mathbf{Z})$
- 8: **if** $h == 90$ **then**
- 9: $\mathbf{Y} \leftarrow \text{Dense}_{90}(\mathbf{z})$
- 10: **else**
- 11: $\mathbf{Y}_{\text{coarse}} \leftarrow \text{Dense}_{52}(\mathbf{z})$ {周级粗预测}
- 12: $\mathbf{Y}_{\text{interp}} \leftarrow \text{Interpolate}(\mathbf{Y}_{\text{coarse}}, 365)$
- 13: $\mathbf{Y} \leftarrow \text{Conv1D_Refine}(\mathbf{Y}_{\text{interp}})$ {精修}
- 14: **end if**
- 15: **return** $\mathbf{Y}$

超参数: Conv1D kernel=7, $d_{\text{model}} = 64$, Transformer 4 头 2 层, DRD 粗预测 52 周。超参数选择依据见第 3.4 节消融实验。

3 结果与分析

数据划分为训练集 (2006-12-16 至 2009-12-31, 1112 天) 和测试集 (2010-01-01 至 2010-11-26, 330 天)。评估策略方面, 90d 预测因测试集 330 天大于输入加输出 180 天, 可在测试集内滑动窗口评估; 365d 预测因测试集 330 天小于输入加输出 455 天, 采用跨边界评估——输入来自训练集最后 90 天, 目标为测试集前 365 天的真实值。所有指标均为原始 kW 量纲。

3.1 主实验结果

表 1: 短期预测 (90 天) 结果

模型	MSE (kW ²)	MAE (kW)
季节性朴素基线	566,327	610.0
LSTM	268,942 $\pm$ 9,986	402.3 $\pm$ 5.5
Transformer	251,819 $\pm$ 15,879	397.2 $\pm$ 15.4
HSMRF	259,395 $\pm$ 27,947	401.8 $\pm$ 19.9

表 2: 长期预测 (365 天) 结果

模型	MSE (kW ²)	MAE (kW)
季节性朴素基线	343,067	444.5
LSTM	591,410 $\pm$ 17,930	600.7 $\pm$ 9.2
Transformer	487,139 $\pm$ 20,849	542.6 $\pm$ 13.2
HSMRF	372,467 $\pm$ 21,793	474.9 $\pm$ 23.2

短期预测 (90d) 方面, 三种深度学习模型性能相近, 均显著优于季节性朴素基线, MSE 较基线降低约 52%。Transformer 最优 (251,819), HSMRF 略次 (259,395), 但三者差异在标准差范围内。这表明短期预测窗口较小时, 模型架构选择影响不大, 关键在于特征工程和训练策略。

长期预测 (365d) 方面出现了一个值得重视的现象——季节性朴素基线在 MSE 和 MAE 两项指标上均优于全部深度学习模型。在各深度学习模型之间, HSMRF 相比标准 Transformer 和 LSTM 仍有明显优势: 相比 Transformer, MSE 降低 23% (487k $\rightarrow$ 372k), MAE 降低 13% (542.6 $\rightarrow$ 474.9); 相比 LSTM, MSE 降低 37% (591k $\rightarrow$ 372k), MAE 降低 21% (600.7 $\rightarrow$ 474.9)。关键观察是: 长期预测中年度季节性是主导因素, 简单的”去年同日值”基线即可获得较好的 MAE; 而深度学习模型在仅有约 1100 天训练数据的小样本条件下, 难以稳定地学习并外推年度周期, 反而因过度拟合训练期噪声而劣于朴素基线。这与时间序列预测领域的普遍规律一致, M-竞赛系列研究表明简单季节性基线在强季节性长程预测中极具竞争力。

3.2 消融实验 (365 天预测)

由于 90d 路径不池化、patch=1, 消融实验仅对 365d 报告。每个消融变体回答一个明确的科学问题:

表 3: 消融实验—365 天预测 MSE

变体	MSE (kW ²)	验证的问题
完整 HSMRF	372,467 $\pm$ 21,793	基线
-w/o MultiScale	377,092 $\pm$ 29,260	多尺度池化是否有效
-w/o Patch	395,180 $\pm$ 30,311	动态 patch 是否有效
-w/o DRD	547,034 $\pm$ 12,217	粗 $\rightarrow$ 精解码是否关键
-w/o Shared	382,614 $\pm$ 40,414	共享编码器是否有效

消融分析显示: DRD 是关键组件, 去掉后 MSE 从 372k 升至 547k (增幅 47%), 验证了直接预测 365 点时的误差累积问题, 粗到精解码通过周级粗预测加插值加 Conv1D 精修有效缓解了这一问题。多尺度池化有正面贡献, 去掉后 MSE 从 372k 升至 377k (增幅 1.2%), 说明分辨率压缩对捕捉长期趋势有帮助但贡献相对较小。Adaptive-Patch 贡献中等, 去掉后 MSE 从 372k 升至 395k (增幅 6%), 说明动态 patch 比固定 patch=1 更优。共享编码器有效, 去掉后 MSE 从 372k 升至 383k (增幅 3%), 说明共享编码器在减少参数量的同时保持性能。

3.3 超参数消融 (365 天预测)

为验证超参数选择的合理性, 对三个关键超参数进行消融实验:

表 4: 超参数消融—365 天预测 MSE

超参数	候选值	MSE (kW ²)
池化压缩因子	2	378,139 $\pm$ 34,028
	3	372,472 $\pm$ 21,795
	4	372,472 $\pm$ 21,795
DRD 精修 kernel	3	387,296 $\pm$ 87,371
	5	406,937 $\pm$ 75,511
	7	372,469 $\pm$ 21,794
粗预测周数	26 (半月)	433,781 $\pm$ 37,703
	52 (周)	372,473 $\pm$ 21,795

超参数消融结果支撑当前配置的合理性: 池化压缩因子 3 和 4 性能相近 (372k), 因子 2 略差 (378k), 说明压缩到约 30 步是合适的平衡点。DRD 精修 kernel 为 7 时最优 (372k), kernel=3 和 5 时性能下降且方差显著增大, 验证了较大 kernel 能够捕捉更宽的时序模式用于精修。粗预测周数 52 优于 26 (372k vs 434k), 说明年度周期的周粒度粗预测比半月粒度更有效, 这符合 52 周 364 天的年度周期直觉。

3.4 可视化




图 1: 短期预测 (90d) 对比曲线




图 2: 长期预测 (365d) 对比曲线




图 3: 消融实验 MSE 对比 (365d)




图 4: 超参数消融对比 (365d)

4 讨论

主要发现如下：

短期预测深度学习优势显著。90 天预测中三种深度学习模型均将 MSE 降至朴素基线的 47% 左右，MAE 降至 66%，说明在短期窗口内模型能学习到近期趋势和周期性模式。Transformer 略优于 LSTM 和 HSMRF，但差异在标准差范围内，提示短期预测的架构选择不如特征工程重要。

长期预测季节性基线优势明显。365 天预测中季节性朴素基线在 MSE 和 MAE 两项指标上均优于所有深度学习模型，这一现象揭示了深度时序预测的关键挑战——在强季节性、小样本条件下模型难以稳定学习年度周期，M-竞赛系列研究早已指出简单季节性方法在长程预测中极具竞争力。

Horizon-aware 设计具有相对价值。尽管所有深度学习模型均劣于季节性基线，但 HSMRF 相比标准 Transformer 仍实现了 23% 的 MSE 降幅，验证了 horizon-aware 架构的合理性。消融实验进一步证实 DRD 是关键组件（去掉后 MSE 升 47%），多尺度池化、Adaptive-Patch、共享编码器均有正面贡献（增幅 1-6%）。

超参数选择有实验支撑。池化压缩因子 3、DRD 精修 kernel=7、粗预测 52 周均被消融实验验证为最优或接近最优配置，其中 kernel=7 时方差显著更小 (21k vs 87k)，提示较大 kernel 能稳定捕捉时序模式。

架构复杂度与数据规模需匹配。当前数据规模 (1112 天) 下多尺度池化和 Adaptive-Patch 等复杂组件的贡献相对有限（增幅 1-6%），提示在小样本场景应优先考虑简单稳健的方法。HSMRF 在 365d 上较大的标准差 ($\pm 22k$) 也提示训练不稳定。

与基线对比方面，LSTM vs Transformer：短期预测 Transformer 略优 (MSE 252k vs 269k)，长期预测 Transformer 显著优 (487k vs 591k)，说明注意力机制在长期依赖建模上有优势。HSMRF vs Transformer：短期预测性能相近 (259k vs 252k)，长期预测 HSMRF 优 (372k vs 487k)，降低 23%。季节性朴素基线的启示：365d 朴素基线 MAE (444.5) 优于所有深度学习模型，提示年度季节性是长期预测的主导因素，深度学习模型可能过度拟合了训练集的噪声而牺牲了对年度模式的捕捉。

4.1 局限性与未来工作

分别训练约束的限制：课程要求 90d 和 365d 模型分别训练，这意味着每个模型实例只看到一个 horizon，分辨率分支是硬编码的架构决策而非可学习的 horizon conditioning。理想方案是训练一个**多任务单模型**：共享编码器 + 两个解码头 (90d/365d)，使用 FiLM (Feature-wise Linear Modulation) 层将 horizon embedding 注入模型，实现真正的 learned horizon conditioning。FiLM 层通过两个 MLP 分别生成 scale 和 shift 参数对中间特征做仿射变换，使模型能够根据预测距离动态调整内部表示，且可泛化到任意 horizon (如 180 天)。这留作未来工作。

数据规模限制：单户家庭 1112 天数据可能不足以训练复杂模型。

天气特征粗粒度：天气变量为月粒度，同月每天相同，信息有限。

单一家庭泛化性：结果可能不具有普遍性。

参考文献

- [1] Hebrail, O. (2012). *Individual household electric power consumption*. UCI Machine Learning Repository.
- [2] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [3] Vaswani, A., et al. (2017). Attention is all you need. *NeurIPS*, 30.
- [4] Nie, Y., et al. (2023). A time series is worth 64 words: Long-term forecasting with transformers. *ICLR*.
- [5] Perez, E., et al. (2018). FiLM: Visual reasoning with a general conditioning layer. *AAAI*, 32(1).