

家庭日用电量的多步预测

LSTM、Transformer 与多分辨率模型的对比实验

姓名：潘沈昕 学号：20255227126

2026 年 7 月

代码地址：<https://github.com/OnlyHero5/hcmrf-household-forecast>

1 问题介绍

1.1 预测任务

实验数据来自 UCI Individual Household Electric Power Consumption 数据集 [1]，包含法国一户家庭 2006 年 12 月至 2010 年 11 月的分钟级用电记录，字段包括总有功功率、总无功功率、电压、电流和三路分表能耗。任务设定为：以最近 90 天为输入，分别预测之后 90 天和 365 天的总有功功率，LSTM、Transformer 和一个改进模型各自独立训练。

数据来自单一家庭，总长度不足四年。当 90 天输入对应 365 天输出时，模型容易退化为仅捕捉平滑的季节曲线，难以反映日级波动。实验中除三种神经网络外，还引入了季节性朴素预测和 Ridge 直接多步预测作为基线，以判断复杂模型相比简单方法是否具有实质性的性能提升。

1.2 日级数据处理

原始字段 `Global_active_power` 表示一分钟区间内的平均有功功率，单位为 kW。为了得到每天实际消耗的电能，按下式将分钟功率积分为日用电量：

$$E_d = \frac{1}{60} \sum_{m \in d} P_m, \quad (1)$$

其中 E_d 的单位为 kWh。无功功率按同样方式积分为日值；三路分表记录的是每分钟 Wh，按天求和即可；电压和电流取日平均值。

原始记录中有 9 天完全缺失。如果直接按已有日期生成滑动窗口，窗口中的相邻行不一定对应相邻两天。预处理时先补全连续日历，再对缺失值做线性插值，连续插值最多 5 天。天气数据采用 Météo-France 发布的月度基础气象数据 [2]，同月内各日共用一组月度统计值。此类变量仅能反映月份之间的差异，对日级用电变化的解释力有限。

处理后的日期范围为 2006-12-16 至 2010-11-26，共 1442 天。以 2010-01-01 为训练/测试边界，训练文件包含 1112 天，测试文件包含 330 天。模型输入由 13 个日级用电及天气变量和 11 个工程特征组成。工程特征包括年、月、星期的周期编码、周末标记、7 天和 30 天滞后，以及对应的滚动均值。

表 1: 日级数据与输入特征概况

项目	数值或处理方式
完整日期范围	2006-12-16 至 2010-11-26, 共 1442 天
训练文件	1112 天, 2006-12-16 至 2009-12-31
测试文件	330 天, 2010-01-01 至 2010-11-26
完全缺失	9 天, 补全日期后插值
训练段日用电量	均值 26.26 kWh, 标准差 10.57 kWh
测试段日用电量	均值 24.70 kWh, 标准差 8.69 kWh
模型输入	90 天 $\times$ 24 维特征

1.3 比较思路

LSTM 通过门控状态保存序列信息 [3], Transformer 则利用自注意力直接建立不同时间位置之间的联系 [4]。PatchTST 将相邻时间点组成 patch, 以更短的 token 序列建模长期依赖 [5]。然而 DLinear 和 M4 竞赛的结果提示, 长周期预测中简单模型未必逊于复杂模型 [6, 9]。

实验主要关注两个方面: LSTM 和 Transformer 在短期与长期预测上的性能差距, 以及降低时间分辨率能否改善 365 天预测。消融实验则用于拆解改进模型中各组件的独立贡献。评价指标采用 MSE 和 MAE, 神经网络均使用 5 个随机种子重复训练, 报告均值与样本标准差。

2 模型

2.1 任务形式

设 $\mathbf{X}_t \in \mathbb{R}^{90 \times 24}$ 表示预测起点前 90 天的输入, $\mathbf{y}_{t,h} \in \mathbb{R}^h$ 表示之后 h 天的日用电量, 其中 $h \in \{90, 365\}$ 。短期和长期模型分别训练:

$$f_h : \mathbf{X}_t \mapsto \hat{\mathbf{y}}_{t,h}. \quad (2)$$

三种模型均直接输出完整预测区间, 不使用递归预测, 从而避免了前一天预测值继续作为后续输入所产生的误差累积; 但输出曲线通常较真实日用电量更为平滑。

2.2 LSTM 与 Transformer

LSTM 使用两层循环网络, 隐藏维度为 128, 层间 dropout 为 0.2。最后一个时间步的隐藏状态经过 $128 \rightarrow 64 \rightarrow h$ 的全连接层得到预测结果。

Transformer 先将 24 维输入映射到 128 维, 并加入正弦位置编码, 随后经过两层、四头的 Transformer Encoder。编码结果沿时间维平均池化, 再由全连接层输出未来 h 天的值。两个基线均未使用特殊结构, 模型之间的差异可归因于序列建模方式本身。

2.3 HCMRF 多分辨率模型

改进模型记为 HCMRF，其设计思想是：90 天预测需要保留日级细节，365 天预测则更依赖低频趋势。两种跨度采用同构模块、分别训练，时间分辨率与输出路径是预设的架构选择，不在两个任务之间共享训练参数。

输入首先经过核大小为 7、通道数为 64 的一维卷积。90 天路径保留全部 90 个时间步，patch 大小为 1；365 天路径将序列平均池化到 30 步，再把相邻 3 步拼成一个 patch，最终得到 10 个 token。patch 投影到 64 维后加入位置编码，并送入两层、四头的 Transformer Encoder。

两条路径的解码器设计差异更为显著。90 天路径仅使用全连接层直接输出 90 个值。365 天路径则分三个阶段：首先预测 52 个粗粒度值（大致对应周级别），随后线性插值至 365 天，最后采用三层一维卷积对局部形状进行微调。模型先确定年度轮廓，再在此基础上叠加日级变化。

90 天多变量输入 → 一维卷积 → 时间分辨率调整 → Patch Transformer → 全局池化
→ 跨度对应的解码器

表 2: 模型规模与主要设置

模型	90 天参数量	365 天参数量	主要结构
LSTM	225,050	242,925	两层 LSTM + 直接多步输出
Transformer	282,266	300,141	两层四头编码器 + 平均池化
HCMRF	151,823	151,823	卷积 + 分块编码 + 分辨率解码

2.4 训练与数据切分

所有神经网络使用 Adam 优化器，学习率为 10^{-3} ，权重衰减为 10^{-5} ，批大小为 32，最多训练 100 轮。验证 MSE 连续 10 轮没有下降时停止训练。5 个随机种子分别为 42、123、456、789 和 2024。

训练窗口按一天步长生成，验证集和最终留出评估各保留一个固定预测起点。训练、验证和最终留出区间的目标不重叠，归一化器只在验证目标开始前的数据上拟合。90 天任务包含 813 个训练窗口，验证目标为 2009-10-03 至 2009-12-31，最终留出目标为 2010-08-29 至 2010-11-26。365 天任务包含 228 个训练窗口，验证目标为 2008-11-27 至 2009-11-26，最终留出目标为 2009-11-27 至 2010-11-26。

测试文件本身只有 330 天，无法单独组成 365 天目标区间。因此，长期任务报告的是跨官方训练/测试文件边界的最终留出区间：完整连续序列末端的 365 天，其中前 35 天位于训练文件末尾。对应验证目标在 2009-11-26 结束，与最终留出目标不重叠；时间顺序也未被打乱 [7, 8]。

3 结果与分析

3.1 主实验结果

评价指标定义为

$$\text{MSE} = \frac{1}{h} \sum_{i=1}^h (y_i - \hat{y}_i)^2, \quad \text{MAE} = \frac{1}{h} \sum_{i=1}^h |y_i - \hat{y}_i|. \quad (3)$$

季节性朴素和 Ridge 是确定性基线，只运行一次。神经网络表中的标准差来自 5 次独立训练。

表 3: 固定测试起点上的预测结果（神经网络为 mean±sample std）

模型	90 天预测		365 天预测	
	MSE (kWh ²)	MAE (kWh)	MSE (kWh ²)	MAE (kWh)
季节性朴素	85.33	7.09	91.16	7.30
Ridge 直接多步	143.85	9.41	65.65	6.31
LSTM	55.66 ± 3.06	5.60 ± 0.15	60.60 ± 2.12	6.09 ± 0.15
Transformer	56.98 ± 1.48	5.66 ± 0.22	62.04 ± 3.84	6.16 ± 0.22
HCMRF	51.59 ± 2.60	5.39 ± 0.15	49.72 ± 0.65	5.45 ± 0.08

90 天任务中, LSTM 和 Transformer 的结果相近, 平均 MSE 分别为 55.66 和 56.98。HCMRF 的 MSE 为 51.59, 相比 LSTM 下降 7.3%, 相比 Transformer 下降 9.5%。在 90 天跨度上, 保留日级分辨率的一维卷积配合较小编码器已能取得较好效果。

365 天任务的差距更大。HCMRF 的平均 MSE 为 49.72, 低于 LSTM 的 60.60、Transformer 的 62.04 和 Ridge 的 65.65; 5 次训练的标准差为 0.65, 也小于另外两种神经网络。Ridge 在 365 天任务上明显优于其 90 天结果——年度低频变化对线性模型而言相对容易拟合。

```
$ python -m src.cli run-all --config configs/default.yaml
Protocol: 90-day input; isolated validation/test targets; 5 seeds
Metric unit: daily energy (kWh)
```

model	horizon	MSE (mean +/- sd)	MAE (mean +/- sd)
lstm	90	55.659 +/- 3.056	5.600 +/- 0.149
transformer	90	56.985 +/- 1.485	5.656 +/- 0.218
hcmrf	90	51.591 +/- 2.596	5.388 +/- 0.147
lstm	365	60.596 +/- 2.122	6.087 +/- 0.146
transformer	365	62.043 +/- 3.842	6.165 +/- 0.218
hcmrf	365	49.725 +/- 0.645	5.451 +/- 0.084

图 1: 正式实验的运行命令与结果截图

3.2 365 天消融实验

为确定各组件的贡献，依次移除 HCM 的池化压缩（仍保留 $patch = 3$ ）、把 $patch$ 大小固定为 1、把粗粒度解码器替换为直接输出 365 天的全连接层。结果见表 4。

表 4: 365 天预测的组件消融结果

配置	MSE (kWh^2)	MAE (kWh)	MSE 变化
完整 HCMRF	49.72 ± 0.65	5.45 ± 0.08	—
移除 HCM 池化压缩	52.23 ± 2.94	5.51 ± 0.11	+5.0%
固定 $patch$ 为 1	51.25 ± 2.04	5.49 ± 0.14	+3.1%
改为直接输出 365 天	62.79 ± 2.90	6.24 ± 0.18	+26.3%

取消粗粒度解码后 MSE 升至 62.79，幅度远超另外两项。HCM 池化压缩和 adaptive $patch$ 有一定贡献，但平均仅差 5.0% 和 3.1%，不同种子之间的排序存在波动。本组实验中，365 天性能的优劣主要取决于输出结构。






图 2: 365 天消融实验 MSE，误差棒为 5 次训练的样本标准差

3.3 预测曲线

图 3 给出随机种子 42 的预测曲线。三种神经网络均能跟踪较慢的季节变化，但日级尖峰普遍难以捕捉。365 天 HCMRF 的曲线最为平滑，这符合预期——先预测 52 个粗粒度值再插值，自然会滤除高频波动。其改进体现在整体水平和低频走势上，日级峰值的偏差仍然较大。



(a) 90 天测试窗口



(b) 365 天测试窗口

图 3: 三种神经网络的预测曲线与真实日用电量

4 讨论

4.1 结果解释

基础模型的对比表明：在这组数据上，自注意力并未自动优于循环网络。输入序列仅有 90 步，数据又仅来自一个家庭，两层 LSTM 已能覆盖主要的变化模式。Transformer 参数更多，测试误差却与 LSTM 接近。

HCMRF 在两个跨度上均取得最低的平均误差，长期任务的提升更为显著。消融实验将原因归结于解码端：先构建年度骨架再填充日级细节，比直接输出 365 个日值更适应当前的数据量。编码端的 HCM 池化压缩和 adaptive patch 提供的改进幅度较小，这两个组件的必要性尚需更多测试起点加以验证。

参数量并非决定性因素。HCMRF 参数少于 LSTM 和 Transformer，365 天误差却更低。在这组数据上，输出结构与预测跨度的匹配程度，比增加隐藏维度更为有效。

4.2 局限与后续改进

实验仅在一个固定测试起点上进行。5 个随机种子只能反映训练波动，不能替代多个时间起点的滚动评估。后续可采用 expanding-window 策略，在不同季节设测试起点，检验模型排序是

否稳定 [8]。

数据局限性同样显著：仅有一个家庭，月度天气变量在同月内完全相同。若拥有更多家庭的数据，可按家庭划分训练集和测试集；在现有数据上，可按工作日/周末、高负荷/低负荷时段分别报告误差。针对长期预测曲线偏平滑的问题，可尝试分位数损失函数或直接输出预测区间，以不确定性范围来刻画一年期的预测值。

实验在 90 天和 365 天两个直接多步预测任务上，比较了三种神经网络和两个简单基线。HCMRF 在两个跨度上均取得了最低的平均 MSE 和 MAE，365 天消融实验表明粗到细的解码方式贡献最大。HCM 池化压缩和 adaptive patch 的改进幅度较小，其必要性尚需更多测试起点加以验证。

参考文献

- [1] G. Hebrail and A. Berard, *Individual Household Electric Power Consumption*, UCI Machine Learning Repository, 2006. doi: <https://doi.org/10.24432/C58K54>.
- [2] Météo-France, *Données climatologiques de base - mensuelles*, data.gouv.fr, accessed July 2026. <https://www.data.gouv.fr/datasets/donnees-climatologiques-de-base-mensuelles>.
- [3] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. doi: <https://doi.org/10.1162/neco.1997.9.8.1735>.
- [4] A. Vaswani et al., “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.
- [5] Y. Nie et al., “A time series is worth 64 words: Long-term forecasting with Transformers,” in *International Conference on Learning Representations*, 2023. <https://openreview.net/forum?id=Jbdc0vT0col>.
- [6] A. Zeng et al., “Are Transformers effective for time series forecasting?” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, pp. 11121–11128, 2023. doi: <https://doi.org/10.1609/aaai.v37i9.26317>.
- [7] L. J. Tashman, “Out-of-sample tests of forecasting accuracy: an analysis and review,” *International Journal of Forecasting*, vol. 16, no. 4, pp. 437–450, 2000. doi: [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0).
- [8] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed., Sec. 5.10, 2021. <https://otexts.com/fpp3/tscv.html>.
- [9] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, “The M4 Competition: 100,000 time series and 61 forecasting methods,” *International Journal of Forecasting*, vol. 36, no. 1, pp. 54–74, 2020. doi: <https://doi.org/10.1016/j.ijforecast.2019.04.014>.

AI 工具使用声明

本报告在行文组织和语言润色阶段使用了 ChatGPT 辅助。数据处理、实验设计、模型实现、实验运行、结果复核和结论分析均由作者潘沈昕独立完成；作者对报告内容及其准确性负责。